

Table of contents

1	1. Introdução	2
2	2. Objetivos	2
	2.1 2.1 Objetivo geral	2
	2.2 2.2 Objetivos específicos	2
3	3. Metodologia	2
	3.1 3.1 Leitura e tratamento dos dados	2
	3.2 3.2 Tratamentos para visualização	3
4	4. Análise das variáveis	3
	4.1 4.1 Área territorial	7
	4.2 4.2 População	8
	4.3 4.3 Densidade demográfica	9
	4.4 4.4 População estimada	10
	4.5 4.5 Escolarização	11
	4.6 4.6 IDHM	12
	4.7 4.7 Mortalidade infantil	13
	4.8 4.8 Receitas/Despesas brutas	14
	4.9 4.9 PIB per capita	15
5	5. Análise descritiva relaciona aos municípios	16
	5.1 5.1 PIB per capita dos 10 maiores municípios em área de MG	16
	5.2 5.2 Top 10 municípios mais desenvolvidos de Minas Gerais	17
6	6. Análise dos gráficos de associação de variáveis	17
	6.1 6.1 PIB per capita e escolarização	18
	6.2 6.2 PIB per capita e mortalidade infantil	20
	6.3 6.3 IDHM e escolarização	21
	6.4 6.4 Mortalidade infantil por faixa de IDHM	22
	6.5 6.5 Receitas e despesas municipais	23
7	REFERÊNCIAS	24
	7.1 APÊNDICE A – Código utilizado na análise	24

UNIVERSIDADE FEDERAL DE MINAS GERAIS

Instituto de Ciências Exatas

Bacharelado em Estatística

Introdução à Ciência de Dados

ANÁLISE EXPLORATÓRIA DE DADOS DOS MUNICÍPIOS DE MINAS GERAIS

Alice de Oliveira Paulino

Geovanna Silva Lacerda

Lívia Neves

Miranda Hágata

Professor: Lourenço

Belo Horizonte – MG

2026

1 1. Introdução

A análise de dados é uma ferramenta importante para compreender diferentes aspectos da realidade social, econômica e demográfica de uma região. A partir da exploração de indicadores estatísticos, é possível identificar padrões, comparar municípios e observar relações entre variáveis que ajudam a explicar fenômenos presentes na sociedade.

Neste trabalho, foi utilizada uma base de dados com informações dos municípios de Minas Gerais, contendo indicadores de população, educação, saúde, desenvolvimento humano, finanças públicas e atividade econômica. Esses dados permitem caracterizar os municípios e observar diferenças socioeconômicas entre eles. A partir dessa base, são realizadas análises exploratórias para descrever o comportamento das variáveis e investigar possíveis relações entre os indicadores selecionados.

2 2. Objetivos

2.1 2.1 Objetivo geral

Realizar uma análise exploratória dos dados dos municípios de Minas Gerais, visando descrever a distribuição dos principais indicadores socioeconômicos e investigar possíveis relações entre eles.

2.2 2.2 Objetivos específicos

- Realizar a leitura e o tratamento da base de dados;
- Verificar e tratar valores ausentes e inconsistências;
- Calcular medidas descritivas das variáveis numéricas;
- Construir representações gráficas (histogramas e boxplots);
- Analisar a distribuição dos indicadores entre os municípios; Investigar relações entre variáveis socioeconômicas selecionadas;
- Calcular e interpretar coeficientes de correlação.

3 3. Metodologia

3.1 3.1 Leitura e tratamento dos dados

A base de dados foi importada para o R por meio da função `read_xlsx()` do pacote `readxl`. O conjunto de dados contém informações referentes aos 853 municípios do estado de Minas Gerais, abrangendo indicadores demográficos, sociais e econômicos.

Inicialmente, foi realizada uma inspeção da estrutura da base utilizando as funções `dim()`, `str()` e `summary()`, com o objetivo de verificar a quantidade de observações, os tipos das variáveis e possíveis inconsistências. Em seguida, os nomes originais das variáveis foram simplificados para facilitar a manipulação e interpretação dos dados ao longo das análises.

Durante a etapa de tratamento, observou-se que a variável de mortalidade infantil havia sido importada como texto devido à presença do símbolo “-”. Como não foi possível concluir se esse símbolo representava ausência de informação ou valor igual a zero, optou-se por convertê-lo para valores ausentes (NA). Posteriormente, a variável foi transformada para o tipo numérico.

Também foi realizada a verificação de valores ausentes, de registros duplicados de municípios e de possíveis inconsistências nos dados. Para isso, foram analisados os intervalos das variáveis numéricas, verificando-se se os valores observados eram compatíveis com a natureza de cada indicador. Não foram identificados municípios duplicados nem valores incompatíveis com os limites esperados das variáveis.

Após essas etapas, a base foi considerada adequada para a realização das análises descritivas, construções gráficas e estudos de associação apresentados nas seções seguintes.

3.2 3.2 Tratamentos para visualização

Para a construção dos gráficos exploratórios, a base foi transformada para o formato longo. Inicialmente, foram selecionadas apenas as variáveis numéricas da base com `select(all_of(dadosnum))`.

Em seguida, foi aplicada a função `pivot_longer()`, reorganizando as variáveis em duas colunas: uma com os nomes das variáveis (Variavel) e outra com seus respectivos valores (Valor). Essa transformação permite a construção de gráficos comparativos no `ggplot2`.

Para o boxplot entre mortalidade infantil e IDHM, foi criada uma variável categórica com base nos quartis do IDHM, utilizada apenas para fins de visualização, sem alteração dos valores originais.

4 4. Análise das variáveis

O comportamento de cada variável numérica foi analisado por meio de recursos gráficos e de um resumo estatístico dos dados.

Histogramas das Variáveis




Figure 1: Figura 1: Histograma de todas as variáveis




Figure 2: Figura 2: Boxplot de todas as variáveis

Na primeira etapa, os recursos visuais utilizados foram o histograma (gráfico de barras que representa a distribuição de frequências de dados contínuos) e o boxplot (diagrama de caixas). A partir deles, é possível observar a variação de frequência de cada variável e visualizar a discrepância entre os dados, o que facilita a identificação de possíveis valores atípicos chamados de outliers.

Tabela 1: Medidas-resumo das variáveis

Variável	Média	Mediana	CV (%)
Área Territorial (km²)	687,59	363,82	140,47
População (Censo 2022)	24.079,71	8.048,00	391,84
Densidade Demográfica (hab/km²)	69,09	22,09	455,11
População Estimada (2025)	25.080,24	8.237,00	393,82
Escolarização 6-14 anos (%)	98,99	99,29	1,37
IDHM	0,67	0,67	7,43
Mortalidade Infantil (óbitos/1000)	18,66	14,51	73,58
Receitas Brutas (R\$)	181.973.241,86	56.697.158,96	468,44
Despesas Brutas (R\$)	173.396.898,73	52.487.344,35	471,28
PIB per Capita (R\$)	34.487,09	24.727,70	96,62

Tabela 2: Valores mínimos e máximos por variável

Variável		Mínimo	Município..Mín.	Máximo	Município..Máx.
Área Territorial (km ²)		3,56	Santa Cruz de Minas	1,072710e+04	João Pinheiro
População (Censo 2022)		833,00	Serra da Saudade	2,315560e+06	Belo Horizonte
Densidade demográfica (hab/km ²)	De-	1,21	Santa Fé de Minas	6,988180e+03	Belo Horizonte
População estimada (2025)	Esti-	856,00	Serra da Saudade	2,415872e+06	Belo Horizonte
Escolarização 6-14 anos (%)		84,92	Simão Pereira	1,000000e+02	Água Comprida
IDHM		0,53	São João das Missões	8,100000e-01	Nova Lima
Mortalidade Infantil (óbitos/1000)	Infan-	1,95	Monte Carmelo	1,000000e+02	Cachoeira Dourada
Receitas (R\$)	Brutas	1.582.348,32	Bandeira do Sul	1,929010e+10	Belo Horizonte
Despesas (R\$)	Brutas	21.904.283,86	Tapiraí	1,942099e+10	Belo Horizonte
PIB per Capita (R\$)		9.139,92	São João das Missões	3,777906e+05	Extrema

Já na segunda etapa, realizou-se um resumo estatístico para sinalizar a média, a mediana (valor que ocupa a posição central dos dados) e o coeficiente de variação (tabela 1). Este último indica o quanto os dados variam em relação à média, de modo que um valor baixo sinaliza pequena dispersão, enquanto um valor alto indica uma grande dispersão dos dados. Além disso, foi possível encontrar o máximo e mínimo de cada variável (tabela 2).

4.1 4.1 Área territorial




Figure 1: Figura 3: Histograma área territorial




Figure 2: Figura 4: Boxplot área territorial

O gráfico de histograma deixa evidente que há uma maior concentração de área territorial entre os primeiros 1500 km². Isso significa que há uma distribuição fortemente assimétrica à direita, em que uma grande massa de dados está localizada no início do gráfico (à esquerda), enquanto o restante do gráfico forma uma cauda longa em direção aos valores mais altos (à direita). Isso reflete a realidade geográfica do estado de Minas Gerais, já que ele é composto por uma enorme quantidade de municípios de pequeno porte territorial.

É importante ressaltar que o gráfico de boxplot reforça essa concentração de dados em cidades de área menor, tendo em vista que sua caixa é mais achatada e demonstra como os valores estão próximos entre si. Além do mais, embora pudesse ser visto no gráfico anterior, nesse torna-se mais evidente a quantidade de outliers no conjunto dados, que é representando pelos pontos pretos fora da caixa. Por fim, a linha preta horizontal que corta a caixa representa a mediana da área territorial, que se posiciona bem próxima de zero. Isso confirma que 50% dos municípios possuem extensões territoriais muito reduzidas. O fato de a distância entre a mediana e o topo da caixa (3º quartil) ser visivelmente maior do que a distância até a base (1º quartil) reforça numericamente a forte assimetria que foi detectada no histograma, mostrando que a dispersão dos dados é muito maior entre as maiores cidades do que entre as menores.

Esse comportamento é completamente coerente com o cálculo das medidas de resumo dessa variável (tabela 1), que resultou nos seguintes valores:

Média: 687,59

Mediana: 363,82

Coefficiente de variação: 140,47%

Como a área média é maior que a mediana, é possível concluir que a maior parte dos dados se concentram em valores mais baixos, o que conclui novamente que Minas possui uma grande quantidade de municípios pequenos, enquanto uma menor parte tem muito mais extensão territorial. Além disso, nota-se que coeficiente de variação indica que esses valores possuem uma dispersão muito alta em relação à média, reforçando a grande heterogeneidade do estado.

4.2 4.2 População




Figure 3: Figura 5: Histograma população




Figure 4: Figura 6: Boxplot população

O gráfico de histograma deixa evidente que há uma maior concentração de população nas faixas iniciais. Isso significa que há uma distribuição fortemente assimétrica à direita, em que a significativa massa de dados está localizada no lado esquerdo do gráfico, enquanto o restante forma uma cauda longa e quase imperceptível em direção aos valores mais altos. Esse comportamento reflete a demografia do estado, que é composta principalmente por muitos municípios com populações muito pequenas.

Ademais, é notório como o gráfico de boxplot reforça essa concentração extrema de dados a partir de uma caixa completamente achatada na base do gráfico, a qual demonstra onde a maior parte dos valores está. Além do mais, o boxplot torna evidente a enorme quantidade de outliers no conjunto de dados, representados pelos pontos pretos acima da caixa fina. A título de curiosidade, o ponto mais isolado no topo do gráfico que ultrapassa a marca de 2 milhões de habitantes representa a capital Belo Horizonte, reforçando a discrepância populacional de Minas Gerais.

Esse comportamento é completamente coerente com o cálculo das medidas de resumo dessa variável (tabela 1), que resultou nos seguintes valores:

Média: 24.079,71

Mediana: 8.048

Coefficiente de variação: 391,84%

O coeficiente de variação indica uma dispersão extremamente alta para os valores da população entre os municípios de Minas Gerais. Novamente, a média maior do que a mediana (proporção de três vezes mais) indica que metade das cidades de Minas possui 8.048 cidadãos ou menos no momento observado.

4.3 4.3 Densidade demográfica




Figure 5: Figura 7: Histograma densidade demográfica




Figure 6: Figura 8: Boxplot densidade demográfica

O gráfico de histograma evidencia uma maior concentração de densidade demográfica nas faixas iniciais. Em suma, há uma distribuição fortemente assimétrica à direita, de modo que a grande massa de dados está localizada no lado esquerdo do gráfico, enquanto o restante forma uma cauda longa e quase imperceptível em direção aos valores mais altos. Esse comportamento reflete a ocupação territorial do estado, que é composta principalmente por muitos municípios com concentrações de habitantes muito pequenas por quilômetro quadrado.

O gráfico de boxplot reforça essa concentração extrema de dados a partir de uma caixa completamente achatada na base do gráfico, a qual demonstra onde a maior parte dos valores está. Além do mais, o boxplot torna evidente a enorme quantidade de outliers no conjunto de dados, representados pelos pontos pretos acima da caixa fina. A título de curiosidade, o ponto mais isolado no topo do gráfico que ultrapassa a marca de 6.000 hab/km² representa a capital Belo Horizonte, reforçando a discrepância de adensamento urbano de Minas Gerais.

Esse comportamento é completamente coerente com o cálculo das medidas de resumo dessa variável (tabela 1), que resultou nos seguintes valores:

Média: 69,09

Mediana: 22,09

Coefficiente de variação: 455,11%

De forma semelhante à última análise, o coeficiente de variação é extremamente alto. É possível concluir que a população estimada na maioria das cidades é relativamente menor do que em uma pequena quantidade de outros municípios.

4.4 4.4 População estimada




Figure 7: Figura 9: Histograma população estimada




Figure 8: Figura 10: Boxplot população estimada

A leitura do histograma revela um cenário similar às variáveis anteriores, de modo que a distribuição dos dados se concentra fortemente logo na parte inicial do gráfico. Esse padrão significa que há uma distribuição fortemente assimétrica à direita, em que a significativa massa de dados está localizada no lado esquerdo do gráfico, enquanto o restante forma uma cauda longa e quase imperceptível em direção aos valores mais altos. Tal configuração traduz a perspectiva demográfica mineira a qual é delimitada por uma vasta quantidade de municípios de pequeno porte populacional.

Olhando para o boxplot, nota-se como ele reforça essa concentração extrema de dados por meio de uma caixa completamente achatada na base, que demonstra onde a maior parte dos valores está agrupada. Além do mais, esse gráfico torna evidente a enorme quantidade de outliers no conjunto de dados, representados pelos pontos pretos acima da caixa fina. A título de curiosidade, de forma similar à última análise, o ponto mais isolado no topo do gráfico que ultrapassa a marca de 2 milhões de habitantes representa a estimativa para a capital Belo Horizonte, reforçando a discrepância populacional de Minas Gerais.

Esse comportamento é completamente coerente com o cálculo das medidas de resumo dessa variável (tabela 1), que resultou nos seguintes valores:

De forma similar à última análise, o coeficiente de variação é extremamente alto. É possível concluir que a população estimada na maioria das cidades é relativamente menor do que em uma pequena quantidade de outros municípios.

4.5 4.5 Escolarização




Figure 9: Figura 11: Histograma escolarização




Figure 10: Figura 12: Boxplot escolarização

O gráfico de histograma deixa evidente que há uma maior concentração da taxa de escolarização nas faixas finais, bem próximas de 100%. Isso significa que, ao contrário das variáveis anteriores, há uma distribuição fortemente assimétrica à esquerda, em que a significativa massa de dados está localizada no lado direito do gráfico, enquanto o restante forma uma cauda longa em direção aos valores mais baixos. Esse comportamento reflete que a grande maioria dos municípios do estado possui índices de escolarização infantil bastante elevados.

Ademais, é notório como o gráfico de boxplot reforça essa concentração extrema de dados na parte superior, apresentando uma caixa localizada no topo do gráfico, a qual demonstra onde a maior parte dos valores está concentrada. A linha preta horizontal que corta essa caixa representa a mediana (99,29%) e, por estar posicionada tão próxima ao limite superior, confirma que pelo menos metade dos municípios mineiros possui índices de escolarização quase totalmente universalizados. Além do mais, o boxplot torna evidente que os outliers, representados pelos pontos pretos, aparecem desta vez abaixo da caixa. Esse formato indica que os municípios discrepantes do conjunto de dados são aqueles que possuem taxas de escolarização abaixo do padrão do estado, chegando a marcas próximas de 85%.

Esse comportamento é completamente coerente com o cálculo das medidas de resumo dessa variável (tabela 1), que resultou nos seguintes valores:



Média: 98,99%

Mediana: 99,29%

Coeficiente de variação: 1,37%

O coeficiente de variação de 1,37% indica dados muito homogêneos. A maior parte dos municípios em Minas possuem taxa de escolarização igual ou menor do que 99,29%. A média de valor menor indica que podem existir algumas cidades com essa taxa menor de forma mais discrepante, puxando a média para baixo.

4.6 4.6 IDHM



O gráfico de histograma deixa evidente que há uma distribuição bem distribuída e equilibrada, praticamente simétrica, de modo que a significativa massa de dados está localizada no centro do gráfico (em torno de 0,6 e 0,7), enquanto as frequências vão diminuindo de forma parecida tanto em direção aos valores mais baixos (à esquerda) quanto aos valores mais altos (à direita). Esse comportamento reflete que a maior parte dos municípios mineiros compartilha de um patamar médio de desenvolvimento humano.

Ademais, é notório como o gráfico de boxplot reforça essa simetria a partir de uma caixa bem distribuída e com uma altura mais evidente, o que demonstra uma dispersão moderada e controlada. A linha preta horizontal que corta essa caixa representa a mediana (0,67) e, por estar posicionada no centro da estrutura, confirma visualmente a simetria dos dados. Além do mais, esse gráfico demonstra a baixíssima quantidade de outliers no conjunto de dados, apresentando apenas um ponto preto isolado no extremo inferior e outro no extremo superior, mostrando que os casos muito discrepantes são raros nessa variável.

Esse comportamento é completamente coerente com o cálculo das medidas de resumo dessa variável (tabela 1), que resultou nos seguintes valores:

Média: 0,67

Mediana: 0,67

Coefficiente de variação: 7,43%

Os valores de média e mediana iguais confirmam que os dados se apresentam de forma simétrica. O coeficiente de variação de 7,43% indica que existe pouca variação entre os dados, ou seja, apesar das desigualdades observadas nas outras variáveis, o IDHM se mantém relativamente estável.

4.7 4.7 Mortalidade infantil




Figure 13: Figura 15: Histograma mortalidade infantil




Figure 14: Figura 16: Boxplot mortalidade infantil

O gráfico de histograma deixa evidente que há uma maior concentração de taxas de mortalidade infantil nas faixas iniciais, com o pico principal ocorrendo entre 10 e 15 óbitos por mil nascidos vivos. Isso significa que há uma distribuição assimétrica à direita, em que a maior parte da massa de dados está localizada no lado esquerdo do gráfico, enquanto o restante forma uma cauda longa que vai se estendendo em direção aos valores mais altos. Esse comportamento reflete que, embora a maioria dos municípios mineiros apresente índices de mortalidade mais controlados, ainda há uma parcela de cidades em patamares agravantes.

Ademais, nota-se como o gráfico de boxplot reforça essa assimetria. Diferente de outras variáveis, a caixa não se apresenta totalmente achatada na base, indicando uma dispersão moderada entre os municípios comuns. A linha preta horizontal que corta a caixa representa a mediana e o fato de ela estar mais próxima da base da caixa reforça graficamente a assimetria à direita. Além do mais, esse gráfico torna evidente a quantidade de outliers no conjunto de dados, representados pelos pontos pretos acima do limite superior, chamando a atenção para municípios isolados onde o índice chega a atingir a alarmante marca de até 100 óbitos por mil nascidos vivos.

Esse comportamento é completamente coerente com o cálculo das medidas de resumo dessa variável (tabela 1), que resultou nos seguintes valores:

Média: 18,66

Mediana: 14,51

Coeficiente de variação: 73,58%

O alto coeficiente de variação confirma que os dados são distribuídos de forma não homogênea. A média maior que a mediana reforça assimetria à direita, com algumas poucas cidades tendo uma taxa de mortalidade infantil mais distantes da média, refletindo essa desigualdade.

4.8 4.8 Receitas/Despesas brutas




Figure 15: Figura 17: Histograma Receitas brutas




Figure 16: Figura 18: Boxplot Receitas brutas




Figure 17: Figura 19: Histograma Despesas brutas




Figure 18: Figura 20: Boxplot Despesas brutas

O gráfico de histograma deixa evidente que há uma maior concentração tanto de receitas quanto de despesas brutas nas faixas iniciais. Isso significa que há uma distribuição fortemente assimétrica à direita, em que a significativa massa de dados está localizada no lado esquerdo do gráfico, enquanto o restante forma uma cauda longa e quase imperceptível em direção aos valores mais altos. Esse comportamento reflete a realidade orçamentária do estado, evidenciando que a grande maioria dos municípios mineiros opera com volumes de recursos financeiros muito pequenos.

Ademais, é notório como o gráfico de boxplot reforça essa concentração extrema de dados a partir de uma caixa completamente achatada na base do gráfico, a qual demonstra onde a maior parte dos valores orçamentários está. Além do mais, o boxplot torna evidente a enorme quantidade de outliers no conjunto de dados, representados pelos pontos pretos acima da caixa fina que se estendem verticalmente de forma expressiva. A título de curiosidade, os pontos mais isolados no topo do gráfico, que chegam a superar a marca de 15 bilhões de reais, representam os valores associados à capital Belo Horizonte, reforçando a brutal discrepância e a centralização de recursos econômicos em Minas Gerais.

Esse comportamento é completamente coerente com o cálculo das medidas de resumo dessas variáveis (tabela 1), que resultaram nos seguintes valores:

Médias: 181mi/173mi

Medianas: 56mi/52mi

Coeficientes de variação: 468%/471%

Esses valores reforçam que existe uma distribuição extremamente desigual do orçamento mineiro. 50% dos municípios possuem renda/despesa na faixa de 50 milhões, no entanto, a média está na faixa de 180 milhões, o que indica que poucas cidades concentram uma movimentação de recursos financeiros fortemente maior.

4.9 4.9 PIB per capita




Figure 19: Figura 21: Histograma PIB per capita




Figure 20: Figura 22: Boxplot PIB per capita

O gráfico de histograma deixa evidente que há uma maior concentração de valores de PIB per capita nas faixas iniciais, com o maior volume de municípios se situando entre 15.000 e 30.000 reais. Isso significa que há uma distribuição assimétrica à direita, em que a significativa massa de dados está localizada no lado esquerdo do gráfico, enquanto o restante forma uma cauda que se estende de maneira contínua em direção aos valores mais altos. Esse comportamento reflete a realidade econômica do estado, mostrando que a maior parte das cidades mineiras opera em patamares de produção de riqueza por habitante relativamente modestos.

Ao analisar o gráfico de boxplot, nota-se como ele reforça essa tendência assimétrica. A caixa não se apresenta completamente achatada na base, indicando que existe uma dispersão interna considerável mesmo entre os municípios que compõem o corpo central dos dados. A linha preta horizontal que corta a estrutura representa a mediana (24.727,70) e, por estar deslocada para a porção inferior da caixa, confirma graficamente a assimetria. Além do mais, o boxplot torna evidente a presença de outliers no conjunto de dados, representados pelos pontos pretos posicionados acima do limite superior, evidenciando cidades com forte atividade econômica concentrada onde o PIB per capita chega a ultrapassar a marca dos 200.000 reais.

Esse comportamento é completamente coerente com o cálculo das medidas de resumo dessa variável (tabela 1), que resultou nos seguintes valores:

Média: 34.487,09

Mediana: 24.727,70

Coeficiente de variação: 96,62%

Essa análise corrobora com a última ao, através de um alto coeficiente de variação, mostrar que os dados se distribuem de forma assimétrica, ou seja, algumas poucas cidades concentram valores de PIB per capita muito maiores do que a maioria, criando a disparidade entre média e mediana.

5 5. Análise descritiva relaciona aos municípios

Embora a variável de municípios seja qualitativa (descreve características, atributos ou categorias que não podem ser medidas numericamente), não significa que ela não possa ser associada com as outras informações fornecidas no banco de dados. Nessa seção, foi realizada essa relação junto com as variáveis PIB per capita, IDHM, taxa de escolarização e mortalidade infantil.

5.1 5.1 PIB per capita dos 10 maiores municípios em área de MG




Figure 3: Figura 23: Gráfico de barras do PIB per capita dos 10 maiores municípios em área de MG

O gráfico evidencia uma desigualdade significativa do PIB per capita entre os maiores municípios mineiros em extensão territorial de Minas Gerais. É perceptível que Paracatu, Uberlândia e Uberaba apresentam uma economia mais influente, mas municípios como Arinos e, principalmente,

Januária possuem um valor de PIB inferior, indicando diferenças importantes no nível de atividade econômica e produtividade local.

5.2 5.2 Top 10 municípios mais desenvolvidos de Minas Gerais




Figure 4: Figura 24: Gráfico de barras 10 municípios mais desenvolvidos de Minas Gerais

O gráfico foi construído a partir de um índice de desenvolvimento criado pela média de quatro indicadores: PIB per capita, IDHM, taxa de escolarização e mortalidade infantil. Inicialmente, todas as variáveis foram padronizadas por meio do escore-z, permitindo que indicadores com escalas diferentes pudessem ser comparados. No caso da mortalidade infantil, o sinal foi invertido para que menores taxas contribuíssem positivamente para o índice. Em seguida, foi calculada a média desses indicadores padronizados, gerando um índice único para cada município. Por fim, os municípios foram ordenados de forma decrescente e os dez maiores valores foram selecionados para compor o gráfico.

6 6. Análise dos gráficos de associação de variáveis

Para compreender melhor a relação entre os indicadores socioeconômicos dos municípios mineiros, foram elaborados gráficos comparando variáveis relacionadas à educação, à saúde, ao desenvolvimento humano e às finanças públicas. A partir dessas visualizações, é possível identificar tendências e padrões que ajudam a entender como esses indicadores se relacionam entre si.

Para realizar essa análise, além do recurso visual, é possível avaliar uma possível associação entre duas variáveis quantitativas (dados que expressam quantidades, medidas ou valores mensuráveis),

por meio de três medidas de correlação. Em geral, essas medidas variam no intervalo de -1 a 1 . Quando o valor da correlação é positivo, indica que, se uma delas aumenta, a tendência é que a outra também cresça e, da mesma forma, se uma diminui, a variável associada tende a decrescer. Por outro lado, caso essa medida seja negativa, a relação ocorre de modo que, se uma variável cresce, a outra tende a diminuir, e vice-versa.

Ademais, se o valor de uma das medidas atingir números próximos de 1 ou de -1 , indica a existência de uma forte correlação entre as variáveis observadas, isto é, há um relevante grau de dependência entre elas. Caso ela seja próxima de 0 , existe uma relação fraca, a qual demonstra pouca associação entre as variáveis.

Para cada tipo de medida, há uma situação a qual melhor se adequa utilizá-la. O Coeficiente de Pearson é normalmente indicado para associações lineares em que os dados não apresentam muita discrepância. Já os Coeficientes de Spearman e de Kendall são calculados a partir da ordenação dos valores em vez dos seus valores brutos, aceitando outliers.

Em relação ao banco de dados analisado, é possível enxergar algumas correlações principais e criar conclusões acerca delas a partir de seus gráficos de dispersão e dos cálculos das medidas desses coeficientes.

6.1 6.1 PIB per capita e escolarização




Figure 5: Figura 25: Gráfico de dispersão PIB per capita e escolarização

Método	Correlação
Pearson	0.000
Spearman	-0.124
Kendall	-0.084

Neste gráfico, observa-se que a escolarização permanece elevada independentemente do nível de PIB per capita do município. Tanto municípios com menor quanto com maior renda apresentam taxas de escolarização muito próximas de 100%.

Embora seja possível notar uma leve tendência positiva, ela não é suficientemente forte para indicar uma relação direta entre as variáveis. Isso sugere que a escolarização básica já está amplamente difundida entre os municípios mineiros, não dependendo exclusivamente do nível de riqueza local.

Essa pouca variabilidade dos níveis de escolarização afeta relativamente os valores das medidas de correlação. Ao calcular os Coeficientes de Pearson, Spearman e Kendall, acha-se os valores -0.0002215448, -0.1242779, -0.0837641, respectivamente. O sinal poderia sugerir uma associação negativa, mas a análise visual do gráfico comprova que, na realidade, a correlação é quase nula. Tais resultados se devem, porque como quase todas as cidades possuem a mesma taxa alta, a linha do gráfico fica constante e, qualquer cidade com PIB muito fora do normal (outlier), puxa o cálculo levemente para o lado negativo.

Portanto, conclui-se que as variáveis não possuem correlação real na prática, e que outros fatores como políticas públicas educacionais e a universalização do acesso à educação básica, podem ter um papel importante nesse resultado de altos índices.

6.2 6.2 PIB per capita e mortalidade infantil

PIB per capita e Mortalidade Infantil




Figure 6: Figura 26: Gráfico de dispersão de PIB per capita e mortalidade infantil

Método	Correlação
Pearson	-0.067
Spearman	-0.226
Kendall	-0.150

Diferentemente do gráfico anterior, a relação entre PIB per capita e mortalidade infantil é mais evidente. Observa-se uma tendência de redução da mortalidade infantil conforme o PIB per capita aumenta.

Esse comportamento pode ser confirmado ao calcular os Coeficientes de Pearson, de Spearman e de Kendall, em que se acham os valores -0.06703182 , -0.2258377 e -0.1495825 , respectivamente. Comparando os três, nota-se que o primeiro apresenta um resultado muito menor em relação aos outros dois porque o PIB possui uma quantidade de valores que variam muito entre si (outliers). Logo, torna-se mais adequado olhar para as duas últimas medidas (-0.2258377 e -0.1495825), as quais são negativas e demonstram que, conforme uma das variáveis cresce, a outra tende a diminuir. Ademais, como esses valores variam no intervalo de 0 a 0,4, há uma correlação fraca entre elas, o que não significa que ela não exista.

Tal percepção sugere que municípios mais ricos tendem a oferecer melhores condições de saúde, infraestrutura e saneamento, fatores que contribuem diretamente para a redução dos óbitos infantis, o que reforça a importância das condições econômicas para os indicadores de saúde.

6.3 IDHM e escolarização




Figure 7: Figura 27: Gráfico de gráfico de dispersão com reta de regressão linear de IDHM e escolarização

Método	Correlação
Pearson	-0.014
Spearman	-0.089
Kendall	-0.060

Ao observar o gráfico, percebe-se uma tendência positiva entre o IDHM e a taxa de escolarização. Em geral, municípios com melhores índices de desenvolvimento humano apresentam taxas de escolarização ligeiramente mais altas.

No entanto, a maioria dos municípios está concentrada próxima ao valor máximo de escolarização, o que revela que esse indicador já apresenta níveis bastante elevados em Minas Gerais. Por isso, embora exista uma relação positiva entre as variáveis, as diferenças observadas não são muito expressivas.

6.4 6.4 Mortalidade infantil por faixa de IDHM




Figure 8: Figura 28: Gráfico boxplot de Mortalidade infantil por faixa de IDHM

Método	Correlação
Pearson	-0.238
Spearman	-0.314
Kendall	-0.211

O gráfico de boxplot mostra como a mortalidade infantil se comporta em diferentes faixas de IDHM. A principal tendência observada é a redução da mortalidade infantil à medida que o IDHM aumenta. Em suma, as faixas com menor desenvolvimento humano apresentam valores mais elevados de mortalidade, enquanto os municípios com IDHM mais alto concentram os menores índices.

Nesse contexto, o cálculo de correlações comprova tal comportamento ao resultar valores de Coeficientes de Pearson, Spearman e Kendall em -0.2375371 , -0.3137683 , -0.2105332 , respectivamente. O valor negativo demonstra que enquanto uma variável cresce (IDH), há o decrescimento da outra (mortalidade). Além disso, é importante ressaltar que como esses resultados obtidos variam no intervalo de 0 a 0,4, há uma correlação fraca entre elas, o que não significa que ela não exista.

Tal percepção pode estar relacionada a fatores como melhores condições de vida, maior acesso aos serviços de saúde e melhores níveis de educação. Dessa forma, o gráfico reforça a ideia de que municípios com maior desenvolvimento humano tendem a oferecer condições mais favoráveis para a saúde da população.

6.5 6.5 Receitas e despesas municipais




Figure 9: Figura 29: Gráfico de gráfico de dispersão com escala logarítmica de Receitas e despesas municipais

Método	Correlação
Pearson	0.995
Spearman	0.982
Kendall	0.905

O gráfico que relaciona receitas e despesas municipais apresenta a associação mais clara entre todas as analisadas. Os pontos formam uma trajetória bastante próxima de uma linha reta linear crescente, indicando que municípios que arrecadam mais também tendem a gastar mais.

Esse destaque significativo é igualmente visto nas medidas de correlação, de modo que os Coeficientes de Pearson, de Spearman e de Kendall resultaram nos valores de 0.9952322, 0.9820892 e 0.9051228, respectivamente. Esse resultado evidencia não só o sinal positivo, o qual indica que as variáveis caminham no mesmo sentido (se uma cresce, a outra também aumenta), como também

revela uma associação muito forte entre elas, já que os coeficientes estão no intervalo entre 0,7 e 1.

É importante destacar, que tal resultado era esperado, uma vez que a capacidade de investimento e de manutenção dos serviços públicos depende diretamente dos recursos disponíveis em cada município. Logo, o gráfico demonstra uma forte relação entre arrecadação e gastos públicos, refletindo a dinâmica financeira das administrações municipais.

7 REFERÊNCIAS

7.1 APÊNDICE A – Código utilizado na análise

```
##BIBLIOTECAS
library(dplyr)
library(ggplot2)
library(MetBrewer)
library(paletteer)
library(purrr)
library(readxl)
library(scales)
library(tidyr)

# Exploração inicial da base.

dim(dados)
names(dados)
str(dados)
summary(dados)

# ----- LIVIA

# Renomeação das variáveis.
dados <- dados %>%
  rename(
    municipio = `Município [-]`,
    area_territorial = `Área Territorial - km² [2025]`,
    populacao = `População no último censo - pessoas [2022]`,
    densidade_demografica = `Densidade demográfica - hab/km² [2022]`,
    populacao_estimada = `População estimada - pessoas [2025]`,
    escolarizacao = `Escolarização <span>6 a 14 anos</span> - % [2022]`,
    idhm = `IDHM <span>Índice de desenvolvimento humano municipal</span> [2010]`,
    mortalidade_infantil = `Mortalidade infantil - óbitos por mil nascidos vivos [2023]`,
    receitas_brutas = `Total de receitas brutas realizadas - R$ [2024]`,
```



```

    despesas_brutas = `Total de despesas brutas empenhadas - R$ [2024]`,
    pib_per_capita = `PIB per capita - R$ [2023]`
  )

names(dados)

# Verificação de valores ausentes.

colSums(is.na(dados))

# Resumo dos valores ausentes.

faltantes <- data.frame(
  variavel = names(dados),
  n_na = colSums(is.na(dados)),
  perc_na = round(
    colSums(is.na(dados)) / nrow(dados) * 100,
    2
  )
)

faltantes

# Identificação de registros inválidos.

sum(dados$mortalidade_infantil == "-")

# Tratamento de valores ausentes.

dados <- dados %>%
  mutate(
    mortalidade_infantil = na_if(
      mortalidade_infantil,
      "-"
    )
  )

# Conversão para formato numérico.

dados <- dados %>%
  mutate(
    mortalidade_infantil =
      as.numeric(mortalidade_infantil))

```

```

str(dados)

colSums(is.na(dados))

faltantes_finais <- data.frame(
  variavel = names(dados),
  n_na = colSums(is.na(dados)),
  perc_na = round(
    colSums(is.na(dados)) / nrow(dados) * 100,
    2))

faltantes_finais

# Verificação de duplicidades.
sum(duplicated(dados$municipio))

# Verificação de valores extremos.

range(dados$idhm, na.rm = TRUE)

range(dados$escolarizacao, na.rm = TRUE)

min(dados$mortalidade_infantil, na.rm = TRUE)

min(dados$area_territorial)

min(dados$populacao)

min(dados$populacao_estimada)

min(dados$pib_per_capita)

min(dados$receitas_brutas)

min(dados$despesas_brutas)

# Resumo da base tratada.
str(dados)

```

```

summary(dados)

# Definição de cores e tema gráfico.

cores <- paletteer::paletteer_d("MetBrewer::Pissaro")

tema_trabalho <- theme_minimal() +
  theme(
    plot.title = element_text(
      face = "bold",
      hjust = 0.5,
      size = 14
    ),
    axis.title = element_text(face = "bold")
  )

# Relação entre PIB e escolarização.

ggplot(
  dados,
  aes(
    x = pib_per_capita,
    y = escolarizacao
  )
) +
  geom_point(
    color = cores[1],
    alpha = 0.7,
    size = 2
  ) +
  scale_x_log10(
    labels = label_number(big.mark = ".")
  ) +
  labs(
    title = "PIB per capita e Escolarização",
    x = "PIB per capita (R$)",
    y = "Escolarização (%)"
  ) +
  tema_trabalho

# Relação entre PIB e mortalidade infantil.

ggplot(

```

```

dados,
aes(
  x = pib_per_capita,
  y = mortalidade_infantil
)
) +
geom_point(
  color = cores[2],
  alpha = 0.7,
  size = 2
) +
geom_smooth(
  method = "lm",
  se = TRUE,
  color = cores[7]
) +
scale_x_log10(
  labels = label_number(big.mark = ".")
) +
labs(
  title = "PIB per capita e Mortalidade Infantil",
  x = "PIB per capita (R$)",
  y = "Mortalidade Infantil"
) +
tema_trabalho
# Relação entre IDHM e escolarização.

ggplot(
  dados,
  aes(
    x = idhm,
    y = escolarizacao
  )
) +
geom_point(
  color = cores[3],
  alpha = 0.7,
  size = 2
) +
geom_smooth(
  method = "lm",
  se = TRUE,
  color = cores[8]

```

```

) +
labs(
  title = "IDHM e Escolarização",
  x = "IDHM",
  y = "Escolarização (%)"
) +
tema_trabalho

# Criação das faixas de IDHM.

dados$faixa_idhm <- cut(
  dados$idhm,
  breaks = quantile(
    dados$idhm,
    probs = seq(0, 1, 0.25),
    na.rm = TRUE
  ),
  include.lowest = TRUE
)

# Mortalidade por faixa de IDHM.
ggplot(
  dados,
  aes(
    x = faixa_idhm,
    y = mortalidade_infantil,
    fill = faixa_idhm
  )
) +
geom_boxplot() +
scale_fill_paletteer_d("MetBrewer::Pissaro") +
labs(
  title = "Mortalidade Infantil por Faixa de IDHM",
  x = "Faixa de IDHM",
  y = "Mortalidade Infantil"
) +
tema_trabalho +
theme(
  legend.position = "none"
)

# Relação entre receitas e despesas.

```

```

ggplot(
  dados,
  aes(
    x = receitas_brutas,
    y = despesas_brutas
  )
) +
  geom_point(
    color = cores[5],
    alpha = 0.7,
    size = 2
  ) +
  scale_x_log10(
    labels = label_number(big.mark = ".")
  ) +
  scale_y_log10(
    labels = label_number(big.mark = ".")
  ) +
  labs(
    title = "Receitas e Despesas Municipais",
    x = "Receitas Brutas (R$)",
    y = "Despesas Brutas (R$)"
  ) +
  tema_trabalho

# Padronização das variáveis.

dados <- dados %>%
  mutate(
    z_pib = as.numeric(scale(pib_per_capita)),
    z_idhm = as.numeric(scale(idhm)),
    z_escolarizacao = as.numeric(scale(escolarizacao)),
    z_mortalidade = -as.numeric(scale(mortalidade_infantil))
  )

# Construção do índice de desenvolvimento.
dados <- dados %>%
  mutate(
    indice_desenvolvimento =
      (z_pib +
       z_idhm +
       z_escolarizacao +
       z_mortalidade) / 4
  )

```

```

)

# Remoção de valores ausentes.
dados_rank <- dados %>%
  filter(!is.na(indice_desenvolvimento))

# Criação do ranking.
ranking <- dados_rank %>%
  arrange(desc(indice_desenvolvimento))

top10 <- ranking %>%
  select(municipio, indice_desenvolvimento) %>%
  slice(1:10)

dados_rank <- dados_rank %>%
  mutate(
    quartil_desenvolvimento =
      ntile(indice_desenvolvimento, 4)
  )

# Classificação dos níveis de desenvolvimento.

dados_rank <- dados_rank %>%
  mutate(
    categoria_desenvolvimento =
      case_when(
        quartil_desenvolvimento == 1 ~ "Baixo",
        quartil_desenvolvimento == 2 ~ "Médio-Baixo",
        quartil_desenvolvimento == 3 ~ "Médio-Alto",
        quartil_desenvolvimento == 4 ~ "Alto"
      )
  )

# Ranking dos municípios mais desenvolvidos.
ggplot(top10,
  aes(x = reorder(municipio,
                  indice_desenvolvimento),
      y = indice_desenvolvimento,
      fill = indice_desenvolvimento)) +
  geom_col() +
  coord_flip() +
  scale_fill_gradientn(colors = cores) +
  labs(
    title = "Top 10 Municípios Mais Desenvolvidos de Minas Gerais",

```

```

    x = "Município",
    y = "Índice de Desenvolvimento"
  ) +
  theme_minimal() +
  theme(
    legend.position = "none"
  )

# ----- HÁGATA - medidas de resumo para variáveis numéricas
numericas <- dados %>% select(where(is.numeric))
# selecionando numéricas

estatisticas <- data.frame(
  Variavel = names(numericas),
  Media = round(sapply(numericas, mean, na.rm = TRUE), 2),
  Mediana = round(sapply(numericas, median, na.rm = TRUE), 2),
  Minimo = round(sapply(numericas, min, na.rm = TRUE), 2),
  Maximo = round(sapply(numericas, max, na.rm = TRUE), 2),
  DP = round(sapply(numericas, sd, na.rm = TRUE), 2),
  CV = round(sapply(numericas, function(x) (sd(x, na.rm = TRUE) / mean(x, na.rm
= TRUE)) * 100), 2)
)
# calculando estatísticas
print(estatisticas)
write.csv(estatisticas, "estatisticas_descritivas.csv", row.names = FALSE)

# CORREÇÃO AQUI: Filtrar apenas as 10 variáveis principais antes de calcular
as médias
colunas_principais <- c(
  "area_territorial", "populacao", "densidade_demografica",
  "populacao_estimada", "escolarizacao", "idhm",
  "mortalidade_infantil", "receitas_brutas", "despesas_brutas", "pib_per_capita"
)
dados_principais <- numericas %>% select(all_of(colunas_principais))

tabela_resumida <- data.frame(
  Variável = c(
    "Área Territorial (km²)",
    "População (Censo 2022)",
    "Densidade Demográfica (hab/km²)",
    "População Estimada (2025)",
    "Escolarização 6-14 anos (%)",
    "IDHM",

```



```

    "Mortalidade Infantil (óbitos/1000)",
    "Receitas Brutas (R$)",
    "Despesas Brutas (R$)",
    "PIB per Capita (R$)"
  ),

  Média = round(sapply(dados_principais, mean, na.rm = TRUE), 2),
  Mediana = round(sapply(dados_principais, median, na.rm = TRUE), 2),
  Mínimo = round(sapply(dados_principais, min, na.rm = TRUE), 2),
  Máximo = round(sapply(dados_principais, max, na.rm = TRUE), 2),
  CV = round(sapply(dados_principais, function(x) (sd(x, na.rm = TRUE) / mean(x,
na.rm = TRUE)) * 100), 2)
)

tabela_resumida$Média <- format(tabela_resumida$Média, big.mark = ".",
decimal.mark = ",")
tabela_resumida$Mediana <- format(tabela_resumida$Mediana, big.mark = ".",
decimal.mark = ",")
tabela_resumida$Mínimo <- format(tabela_resumida$Mínimo, big.mark = ".",
decimal.mark = ",")
tabela_resumida$Máximo <- format(tabela_resumida$Máximo, big.mark = ".",
decimal.mark = ",")

print(tabela_resumida)
# criando tabela resumida

encontrar_municipio <- function(df, var, tipo = "max") {
  df_clean <- df[!is.na(df[[var]]), ]

  if (nrow(df_clean) == 0) {
    return(NA)
  }

  if (tipo == "max") {
    valor <- max(df_clean[[var]], na.rm = TRUE)
  } else {
    valor <- min(df_clean[[var]], na.rm = TRUE)
  }

  municipios <- df_clean$municipio[df_clean[[var]] == valor]

  return(municipios[1])
}

```

```

tabela_extremos <- data.frame(
  Variável = c(
    "Área Territorial (km²)",
    "População (Censo 2022)",
    "Densidade Demográfica (hab/km²)",
    "População Estimada (2025)",
    "Escolarização 6-14 anos (%)",
    "IDHM",
    "Mortalidade Infantil (óbitos/1000)",
    "Receitas Brutas (R$)",
    "Despesas Brutas (R$)",
    "PIB per Capita (R$)"
  ),

  `Mínimo` = c(
    min(dados$area_territorial, na.rm = TRUE),
    min(dados$populacao, na.rm = TRUE),
    min(dados$densidade_demografica, na.rm = TRUE),
    min(dados$populacao_estimada, na.rm = TRUE),
    min(dados$escolarizacao, na.rm = TRUE),
    min(dados$idhm, na.rm = TRUE),
    min(dados$mortalidade_infantil, na.rm = TRUE),
    min(dados$receitas_brutas, na.rm = TRUE),
    min(dados$despesas_brutas, na.rm = TRUE),
    min(dados$pib_per_capita, na.rm = TRUE)
  ),

  `Município (Mín)` = c(
    encontrar_municipio(dados, "area_territorial", "min"),
    encontrar_municipio(dados, "populacao", "min"),
    encontrar_municipio(dados, "densidade_demografica", "min"),
    encontrar_municipio(dados, "populacao_estimada", "min"),
    encontrar_municipio(dados, "escolarizacao", "min"),
    encontrar_municipio(dados, "idhm", "min"),
    encontrar_municipio(dados, "mortalidade_infantil", "min"),
    encontrar_municipio(dados, "receitas_brutas", "min"),
    encontrar_municipio(dados, "despesas_brutas", "min"),
    encontrar_municipio(dados, "pib_per_capita", "min")
  ),

  `Máximo` = c(
    max(dados$area_territorial, na.rm = TRUE),

```

```

        max(dados$populacao, na.rm = TRUE),
        max(dados$densidade_demografica, na.rm = TRUE),
        max(dados$populacao_estimada, na.rm = TRUE),
        max(dados$escolarizacao, na.rm = TRUE),
        max(dados$idhm, na.rm = TRUE),
        max(dados$mortalidade_infantil, na.rm = TRUE),
        max(dados$receitas_brutas, na.rm = TRUE),
        max(dados$despesas_brutas, na.rm = TRUE),
        max(dados$pib_per_capita, na.rm = TRUE)
    ),

    `Município (Máx)` = c(
        encontrar_municipio(dados, "area_territorial", "max"),
        encontrar_municipio(dados, "populacao", "max"),
        encontrar_municipio(dados, "densidade_demografica", "max"),
        encontrar_municipio(dados, "populacao_estimada", "max"),
        encontrar_municipio(dados, "escolarizacao", "max"),
        encontrar_municipio(dados, "idhm", "max"),
        encontrar_municipio(dados, "mortalidade_infantil", "max"),
        encontrar_municipio(dados, "receitas_brutas", "max"),
        encontrar_municipio(dados, "despesas_brutas", "max"),
        encontrar_municipio(dados, "pib_per_capita", "max")
    )
)

tabela_extremos$Mínimo <- format(round(tabela_extremos$Mínimo, 2),
    big.mark = ".", decimal.mark = ",")
tabela_extremos$Máximo <- format(round(tabela_extremos$Máximo, 2),
    big.mark = ".", decimal.mark = ",")

#exibir
print(tabela_extremos)

# ----- geovanna linda ----- <3

dadosnum <- names(dados)[sapply(dados, is.numeric)]
numlg <- dados %>%
    select(all_of(dadosnum)) %>%
    pivot_longer(cols = everything(), names_to = "Variavel", values_to = "Valor")

#Gráficos de todas variáveis

```

```

#HISTOGRAMA
ggplot(numlg, aes(x = Valor)) +
  geom_histogram(fill = cores[1], color = "black", bins = 30, na.rm = TRUE) +
  facet_wrap(~Variavel, scales = "free") +
  labs( title = "Histogramas das Variáveis",
        x = "Valores",
        y = "Frequência") + tema_trabalho

#BOXPLOT
ggplot(numlg, aes(y = Valor)) +
  geom_boxplot(fill = cores[4], color = "black", na.rm = TRUE) +
  facet_wrap(~Variavel, scales = "free") +
  labs(title = "Boxplots das Variáveis",
        y = "Valores",
        x = "") +
  tema_trabalho +
  theme(
    axis.text.x = element_blank(),
    axis.ticks.x = element_blank())

#10 municipios
#FILTRAR
maiores_areas <- dados %>%
  arrange(desc(area_territorial)) %>%
  slice_head(n = 10)

#GRÁFICO PIB PER CAPITA
ggplot(maiores_areas, aes(x = reorder(municipio, -pib_per_capita), y =
pib_per_capita)) +
  geom_col(fill = cores[2], color = "black", alpha = 0.8) +
  scale_y_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",", "")) +
  labs( title = "PIB per Capita dos 10 Maiores Municípios em Área de MG",
        x = "Município",
        y = "PIB per Capita (R$)") + tema_trabalho +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

##graficos isolados (boxplot)
#ÁREA TERRITORIAL
ggplot(dados, aes(y = area_territorial)) +
  geom_boxplot(fill = cores[4], color = "black", na.rm = TRUE) +
  scale_y_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",", "")) +
  labs(title = "Boxplot área Territorial (km²)", y = "Área Territorial", x =

```

```

    "") +
      tema_trabalho + theme(axis.text.x = element_blank(), axis.ticks.x =
element_blank())

#POPULAÇÃO
ggplot(dados, aes(y = populacao)) +
  geom_boxplot(fill = cores[4], color = "black", na.rm = TRUE) +
  scale_y_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",")) +
  labs(title = "População", y = "População (pessoas)", x = "") +
  tema_trabalho + theme(axis.text.x = element_blank(), axis.ticks.x =
element_blank())

#DENSIDADE DEMOGRÁFICA
ggplot(dados, aes(y = densidade_demografica)) +
  geom_boxplot(fill = cores[4], color = "black", na.rm = TRUE) +
  scale_y_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",")) +
  labs(title = "Boxplot Densidade Demográfica (hab/km²)", y = "Densidade
Demográfica", x = "") +
  tema_trabalho + theme(axis.text.x = element_blank(), axis.ticks.x =
element_blank())

#POPULAÇÃO ESTIMADA
ggplot(dados, aes(y = populacao_estimada)) +
  geom_boxplot(fill = cores[4], color = "black", na.rm = TRUE) +
  scale_y_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",")) +
  labs(title = "Boxplot População estimada", y = "População Estimada (Pessoas)",
x = "") +
  tema_trabalho + theme(axis.text.x = element_blank(), axis.ticks.x =
element_blank())

#ESCOLARIZAÇÃO
ggplot(dados, aes(y = escolarizacao)) +
  geom_boxplot(fill = cores[4], color = "black", na.rm = TRUE) +
  scale_y_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",")) +
  labs(title = "boxplot Taxa de Escolarização (6 a 14 anos)", y = "Escolarização
(%)", x = "") +
  tema_trabalho + theme(axis.text.x = element_blank(), axis.ticks.x =
element_blank())

```

```

#IDHM
ggplot(dados, aes(y = idhm)) +
  geom_boxplot(fill = cores[4], color = "black", na.rm = TRUE) +
  scale_y_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",",)) +
  labs(title = "Boxplot IDHM", y = "Índice de Desenvolvimento Humano Municipal",
x = "") +
  tema_trabalho + theme(axis.text.x = element_blank(), axis.ticks.x =
element_blank())

#MORTALIDADE INFANTIL
ggplot(dados, aes(y = mortalidade_infantil)) +
  geom_boxplot(fill = cores[4], color = "black", na.rm = TRUE) +
  scale_y_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",",)) +
  labs(title = "Boxplot mortalidade infantil", y = "Óbitos por mil nascidos
vivos", x = "") +
  tema_trabalho + theme(axis.text.x = element_blank(), axis.ticks.x =
element_blank())

#RECEITAS BRUTAS
ggplot(dados, aes(y = receitas_brutas)) +
  geom_boxplot(fill = cores[4], color = "black", na.rm = TRUE) +
  scale_y_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",",)) +
  labs(title = "Boxplo Receitas Brutas", y = "Receitas (R$)", x = "") +
  tema_trabalho + theme(axis.text.x = element_blank(), axis.ticks.x =
element_blank())

#DESPESAS BRUTAS
ggplot(dados, aes(y = despesas_brutas)) +
  geom_boxplot(fill = cores[4], color = "black", na.rm = TRUE) +
  scale_y_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",",)) +
  labs(title = "Boxplot Despesas Brutas", y = "Despesas (R$)", x = "") +
  tema_trabalho + theme(axis.text.x = element_blank(), axis.ticks.x =
element_blank())

#PIB PER CAPITA
ggplot(dados, aes(y = pib_per_capita)) +
  geom_boxplot(fill = cores[4], color = "black", na.rm = TRUE) +
  scale_y_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",",)) +

```

```

    labs(title = "Boxplot PIB per Capita", y = "PIB per Capita (R$)", x = "") +
      tema_trabalho + theme(axis.text.x = element_blank(), axis.ticks.x =
element_blank())

##graficos isolados (boxplot)
#ÁREA TERRITORIAL
ggplot(dados, aes(x = area_territorial)) +
  geom_histogram(fill = cores[1], color = "black", bins = 30, na.rm = TRUE) +
  scale_x_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",")) +
  labs(title = "Histograma Área Territorial (km²)", x = "Área Territorial", y
= "Frequência") +
  tema_trabalho

#POPULAÇÃO
ggplot(dados, aes(x = populacao)) +
  geom_histogram(fill = cores[1], color = "black", bins = 30, na.rm = TRUE) +
  scale_x_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",")) +
  labs(title = "Histograma População", x = "População (Pessoas)", y =
"Frequência") +
  tema_trabalho

#DENSIDADE DEMOGRÁFICA
ggplot(dados, aes(x = densidade_demografica)) +
  geom_histogram(fill = cores[1], color = "black", bins = 30, na.rm = TRUE) +
  scale_x_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",")) +
  labs(title = "Histograma Densidade Demográfica (hab/km²)", x = "Densidade
Demográfica", y = "Frequência") +
  tema_trabalho

#POPULAÇÃO ESTIMADA
ggplot(dados, aes(x = populacao_estimada)) +
  geom_histogram(fill = cores[1], color = "black", bins = 30, na.rm = TRUE) +
  scale_x_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",")) +
  labs(title = "Histograma População Estimada", x = "População Estimada
(Pessoas)", y = "Frequência") +
  tema_trabalho

#ESCOLARIZAÇÃO
ggplot(dados, aes(x = escolarizacao)) +

```

```

    geom_histogram(fill = cores[1], color = "black", bins = 30, na.rm = TRUE) +
    scale_x_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",")) +
    labs(title = "Histograma Taxa de Escolarização (6 a 14 anos)", x =
"Escolarização (%)", y = "Frequência") +
    tema_trabalho

#IDHM
ggplot(dados, aes(x = idhm)) +
    geom_histogram(fill = cores[1], color = "black", bins = 30, na.rm = TRUE) +
    scale_x_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",")) +
    labs(title = "Histograma IDHM", x = "Índice de Desenvolvimento Humano
Municipal", y = "Frequência") +
    tema_trabalho

#MORTALIDADE INFANTIL
ggplot(dados, aes(x = mortalidade_infantil)) +
    geom_histogram(fill = cores[1], color = "black", bins = 30, na.rm = TRUE) +
    scale_x_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",")) +
    labs(title = "Histograma Mortalidade Infantil", x = "Óbitos por mil nascidos
vivos", y = "Frequência") +
    tema_trabalho

#RECEITA
ggplot(dados, aes(x = receitas_brutas)) +
    geom_histogram(fill = cores[1], color = "black", bins = 30, na.rm = TRUE) +
    scale_x_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",")) +
    labs(title = "Histograma Receitas Brutas", x = "Receitas (R$)", y =
"Frequência") +
    tema_trabalho

#DESPESAS BRUTAS
ggplot(dados, aes(x = despesas_brutas)) +
    geom_histogram(fill = cores[1], color = "black", bins = 30, na.rm = TRUE) +
    scale_x_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",")) +
    labs(title = "Histograma Despesas Brutas ", x = "Despesas (R$)", y =
"Frequência") +
    tema_trabalho

```



```

#PIB PR CAPITA
ggplot(dados, aes(x = pib_per_capita)) +
  geom_histogram(fill = cores[1], color = "black", bins = 30, na.rm = TRUE) +
  scale_x_continuous(labels = scales::label_number(big.mark = ".", decimal.mark
= ",",)) +
  labs(title = "Histograma PIB per Capita", x = "PIB per Capita (R$)", y =
"Frequência") +
  tema_trabalho

# ALICE
# Cálculo das correlações

library(tidyverse)
library(vcd)

# PIB x Escolarização
pib_escol_pearson <- cor(dados$pib_per_capita, dados$escolarizacao, method
= "pearson")
pib_escol_spearman <- cor(dados$pib_per_capita, dados$escolarizacao, method
= "spearman")
pib_escol_kendall <- cor(dados$pib_per_capita, dados$escolarizacao, method
= "kendall")

# PIB x Mortalidade
pib_mort_pearson <- cor(dados$pib_per_capita, dados$mortalidade_infantil,
method = "pearson", use = "complete.obs")
pib_mort_spearman <- cor(dados$pib_per_capita, dados$mortalidade_infantil,
method = "spearman", use = "complete.obs")
pib_mort_kendall <- cor(dados$pib_per_capita, dados$mortalidade_infantil,
method = "kendall", use = "complete.obs")

# IDH x Escolarização
idh_escol_pearson <- cor(dados$idhm, dados$escolarizacao, method = "pearson",
use = "complete.obs")
idh_escol_spearman <- cor(dados$idhm, dados$escolarizacao, method = "spearman",
use = "complete.obs")
idh_escol_kendall <- cor(dados$idhm, dados$escolarizacao, method = "kendall",
use = "complete.obs")

# Mortalidade infantil x IDH
idh_mort_pearson <- cor(dados$idhm, dados$mortalidade_infantil, method =

```

```

"pearson", use = "complete.obs")
  idh_mort_spearman <- cor(dados$idhm, dados$mortalidade_infantil, method =
"spearman", use = "complete.obs")
  idh_mort_kendall <- cor(dados$idhm, dados$mortalidade_infantil, method =
"kendall", use = "complete.obs")

# Receitas x Despesas Municipais
desp_rec_pearson <- cor(dados$despesas_brutas, dados$receitas_brutas, method
= "pearson", use = "complete.obs")
desp_rec_spearman <- cor(dados$despesas_brutas, dados$receitas_brutas, method
= "spearman", use = "complete.obs")
desp_rec_kendall <- cor(dados$despesas_brutas, dados$receitas_brutas, method
= "kendall", use = "complete.obs")

# ---- Tabelas separadas ----

tabela_pib_escol <- tibble(
  Método = c("Pearson", "Spearman", "Kendall"),
  Correlação = round(c(pib_escol_pearson, pib_escol_spearman,
pib_escol_kendall), 3)
)

tabela_pib_mort <- tibble(
  Método = c("Pearson", "Spearman", "Kendall"),
  Correlação = round(c(pib_mort_pearson, pib_mort_spearman, pib_mort_kendall),
3)
)

tabela_idh_escol <- tibble(
  Método = c("Pearson", "Spearman", "Kendall"),
  Correlação = round(c(idh_escol_pearson, idh_escol_spearman,
idh_escol_kendall), 3)
)

tabela_idh_mort <- tibble(
  Método = c("Pearson", "Spearman", "Kendall"),
  Correlação = round(c(idh_mort_pearson, idh_mort_spearman, idh_mort_kendall),
3)
)

tabela_desp_rec <- tibble(
  Método = c("Pearson", "Spearman", "Kendall"),
  Correlação = round(c(desp_rec_pearson, desp_rec_spearman, desp_rec_kendall),

```

3)
)

⋮